

מה באמת קובע את החשבון של סוכן תוכנה

מאמר חדש מדד כמה טוקנים צורכים שמונה מודלים כשהם פותרים 500 באגים אמיתיים, וארבע פעמים כל אחד. התוצאה מפתיעה פחות בגודל ההוצאה ויותר במקור שלה: רוב הכסף הולך על טקסט שהסוכן קורא שוב, לא על טקסט שהוא כותב. המסמך הזה בודק את הממצאים מול המקורות, ומתקן מספר אחד שהמאמר עצמו טועה בו.

9 באוקטובר 2026 · מהדורה מס' 12 · 1132 מילים

מעמד המסמך

זהו מסמך הרקע של מערכת "היום בקיצור", והוא המקור שהכתבה הראשית מפנה אליו. הוא נכתב בעקבות מאמר אקדמי בן 26 עמודים ו-10,218 מילים שהתקבל ב-8 באוקטובר 2026, ושואל כמה עולה להפעיל סוכן תוכנה אוטונומי ולמה. המאמר שהתקבל אינו מתפרסם. הוא נשמר בעותק המקורי בתוך המאגר של העיתון, כך שאפשר לבדוק מה נלקח ממנו ומה נדחה. זהותו, תאריכו ורשימת מחבריו אומתו מול דף המאמר ב-arXiv, והתקציר שם זהה לזה שבקובץ. כל מספר שמופיע כאן נבדק מול גוף המאמר ולא מול התקציר שלו, משום שבמקרה הזה השניים אינם מסכימים. העיתון כותב את מסמך הרקע שלו בעצמו משום שמאמר שעבר ביקורת עמיתים הוא מקור, לא ערובה. בבדיקה נמצאה במאמר טעות מספרית אחת, שתי הגזמות בתקציר ביחס לנתונים שבגוף, והפניה שגויה לתרשים. הממצא המרכזי שורד את כל ארבעתן.

תוכן

1. מה נמדד, ואיך
2. סדר הגודל: פי אלפים, לא פי עשרות
3. הכסף הולך על קריאה חוזרת
4. יותר טוקנים אינם קונים יותר דיוק
5. ההבדל הוא במודל, לא במשימה
6. הערכת קושי אנושית מנבאת חלש
7. הסוכן אינו יודע לתמחר את עצמו
8. מה נדחה מהמאמר
9. מה לא ניתן היה לאמת

1. מה נמדד, ואיך

המאמר נושא את הכותרת How Do AI Agents Spend Your Money, והוא פורסם ב-arXiv תחת המזהה 2604.22750. הגרסה שנבדקה כאן היא v3, שעלתה ב-2 באוקטובר 2026. שמונה מחברים חתומים עליו, ממישיגן, מאוניברסיטת טקסס באוסטין, מסטנפורד, מ-All Hands AI, מגוגל דיפמינד, מMIT ו-MIT. הניסוי עצמו מוגדר בצמצום, וזה היתרון שלו. סוכן אחד, OpenHands, מופעל על 500 באגים אמיתיים מתוך SWE-bench Verified, אוסף שנבנה מתקלות שדווחו במאגרי קוד פופולריים בפייתון ועבר אימות אנושי. שמונה מודלים מריצים את אותו מסלול בדיוק: Claude Sonnet בגרסאות 3.7, 4 ו-4.5, GPT-5, Qwen3-Coder-480B, ו-GPT-5.2, Gemini-3-Pro-Preview ו-Kimi-K2. כל מודל רץ ארבע פעמים על כל משימה, כדי שאפשר יהיה להפריד בין הבדל אמיתי לבין רעש.

הכותרת מדברת על סוכני AI, אבל כל הראיות שבמאמר הן על כתיבת קוד בפייתון, דרך מסגרת סוכן אחת. סוכן שמזמין טיסה או קורא דואר לא נמדד כאן. פרק המגבלות של המאמר מודה במספר המודלים המוגבל, אך אינו מזכיר את הצמצום הזה.

2. סדר הגודל: פי אלפים, לא פי עשרות

תרשים 1 במאמר מעמיד זה מול זה שלושה שימושים במודל שפה. שאלה שדורשת הסקה על קוד צורכת בממוצע 1,190 טוקנים ועולה 1.6 סנט. שיחה על קוד צורכת 3,390 טוקנים ועולה 2.3 סנט. משימת סוכן צורכת 4.17 מיליון טוקנים ועולה 1.857 דולר.

היחס בין משימת סוכן לשאלת הסקה הוא 3,504. מול שיחה הוא 1,230. במונחי כסף משימת סוכן יקרה פי 116 משאלת הסקה. אלה מספרים שהעיתון חישב מתוך הערכים שבתרשים, ולא ציטט.

המספר השלישי בתרשים הוא החשוב. היחס בין טוקני קלט לטוקני פלט הוא 0.16 בהסקה על קוד ו-1.33 בשיחה. במשימת סוכן הוא 153.85. כלומר על כל מילה שהסוכן כותב, הוא קורא בערך מאה וחמישים.

3. הכסף הולך על קריאה חוזרת

המאמר מחלק כל מסלול לחמישה שלבים ומודד כמה נצרך בכל אחד: הקמה 9.98 אחוזים, חקירה 30.37, תיקון 33.53, אימות 16.59 וסגירה 9.53. חקירה ותיקון יחד הם 63.9 אחוזים, כלומר כשני שלישים. גם זה חישוב של העיתון.

בכל אחד מחמשת השלבים, הקטגוריה הגדולה ביותר היא קריאה מהמטמון. ספקים כמו Anthropic מתמחרים הקשר שכבר נשלח פעם אחת בהנחה חדה, ובכל זאת הקריאות החוזרות מהמטמון הן ההוצאה הדומיננטית בכל שלב, גם בשלבים שבהם הסוכן כותב הכי הרבה.

ההסבר מכני. מסלול של סוכן מוסיף להקשר בכל סיבוב: פלט של פקודה, תוכן של קובץ, שגיאה של בדיקה. ההקשר אינו מתאפס, ולכן כל סיבוב נוסף נושא על גבו את כל מה שקדם לו. החשבון אינו גדל לפי מה שהסוכן מייצר, הוא גדל לפי מה שהוא כבר ראה.

ניתוח ברמת הסיבוב הבודד, על באג מתוך הספרייה האסטרונומית astropy, מראה את אותה תמונה: עלות הקריאה מהמטמון עולה בהתמדה לאורך המסלול, והקפיצות החדות נגרמות על ידי פעולות שמכניסות תוכן חדש להקשר, כמו פתיחת קובץ או הרצת בדיקה.

4. יותר טוקנים אינם קונים יותר דיוק

זה הממצא שהכי קל להתעלם ממנו. כשהמשימות מסודרות לפי עלות ומחולקות לרבעונים, שיעור ההצלחה אינו עולה עם ההוצאה. הוא מגיע לשיא ברבעונים האמצעיים ויורד ברבעון היקר ביותר.

המאמר מקשר זאת לתופעה שתוארה בספרות כהרחבת זמן בדיקה הפוכה: מעבר לנקודה מסוימת, חישוב נוסף פוגע בביצועים במקום לשפר אותם. ההסבר ההתנהגותי שהמאמר מציע הוא פשוט יותר. מסלול יקר אינו מסלול שעבד קשה, הוא לרוב מסלול שהסתבך.

המשמעות המעשית למי שמשלם: החשבון הגבוה ביותר שתקבלו בסוף החודש יהיה, בסבירות גבוהה, עבור המשימות שהסוכן לא הצליח לפתור.

5. ההבדל הוא במודל, לא במשימה

Kimi-K2 ו-Sonnet 4.5 צורכים יותר מ-1.5 מיליון טוקנים מעבר ל-GPT-5 על אותו אוסף משימות. ההסבר המתבקש הוא שהם פשוט נפלו על משימות קשות יותר, והמאמר חוסם אותו בצורה נקייה.

הוא מבודד שתי קבוצות משנה: 230 משימות שכל המודלים הצליחו בהן, ו-100 משימות שכולם נכשלו בהן. דירוג היעילות נשמר בשתייהן. כשהמשימה זהה והתוצאה זהה, ההבדל בהוצאה נותר, ולכן הוא תכונה של המודל.

ספירת הפעולות מראה במה מדובר. Kimi-K2 חוזר ופותח את אותו קובץ בכ-52 אחוזים מהצפיות שלו, וחוזר ועורך את אותו מקום בכ-50 אחוזים מהעריכות. GPT-5 חוזר על כ-27 אחוזים מהצפיות. סוכן יקר הוא סוכן ששוכח איפה כבר היה.

6. הערכת קושי אנושית מנבאת חלש

SWE-bench Verified כל משימה נושאת תווית קושי שנתנו לה מהנדסים: פחות מ-15 דקות, רבע שעה עד שעה, או יותר משעה. השאלה המעשית היא אם אפשר להשתמש בתווית הזאת כדי לנחש עלות מראש.

הקשר קיים אך חלש. מקדם קנדל טאו-בי הוא 0.32, עם רווח סמך של 95 אחוזים בין 0.25 ל-0.38. ההתפלגויות נחתכות זו בזו: 6.7 אחוזים מהמשימות שתויגו כקצרות מ-15 דקות צרכו יותר מהממוצע של המשימות שתויגו כארוכות משעה, ו-11.1 אחוזים מהארוכות צרכו פחות מהממוצע של הקצרות.

כלומר אומדן אנושי של קושי אינו אומדן של מחיר. מי שמתקצב לפי התחושה כמה המשימה נשמעת קשה, מתקצב לפי מדד שההתאמה שלו למציאות בינונית.

7. הסוכן אינו יודע לתמחר את עצמו

החלק האחרון של המאמר שואל אם המודל עצמו יכול להעריך, לפני שהוא מתחיל, כמה המשימה תעלה. התשובה שלילית, והמדידה מפורטת.

המתאם הגבוה ביותר שנמדד הוא 0.39, אצל Sonnet 4.5 בניבוי טוקני הפלט שלו. Gemini-3-Pro נע סביב 0.04 עד 0.05, כלומר קרוב לניחוש. המודלים גם מטים את ההערכה לכיוון אחד: הם נוטים להמעיט.

המספר שמסכם את זה הוא יחס העלות: כמה עולה הניבוי ביחס למשימה עצמה. אצל Sonnet 3.7 הוא 2.29 ואצל Sonnet 4 הוא 2.09. שני המודלים האלה גובים יותר מכפול ממחיר המשימה רק כדי לנחש מה יהיה מחיר המשימה, ולא מגיעים בתמורה למתאם הגבוה ביותר. אצל Sonnet 4.5 היחס הוא 0.32 ואצל GPT-5.2 הוא 0.05.

8. מה נדחה מהמאמר

ארבעה דברים במאמר לא עברו את הבדיקה, ולכן אינם מודפסים בעיתון בצורה שבה הם מופיעים שם.

הראשון הוא מספר שגוי. בפרק 5 כתוב שטוקן פלט מתומחר גבוה פי 80 בערך מקריאה מהמטמון. אותו פרק מזהיר שהניתוח שלו נעשה כולו על Claude Sonnet 4.5, ומחירון Anthropic, שהמאמר עצמו מפנה אליו, קובע לדגם הזה 15 דולר למיליון טוקני פלט מול 30 סנט למיליון טוקני קריאה מהמטמון. היחס הוא 50, לא 80. הטענה שהמאמר בונה על המספר שורדת את התיקון ואף מתחזקת: אם הפלט יקר פי 50 בלבד ועדיין הקריאה החוזרת מכריעה את החשבון, הנפח המצטבר גדול אף יותר ממה שהמאמר טוען.

השני הוא פער בין התקציר לגוף. התקציר אומר שמשימת סוכן צורכת פי 1,000 טוקנים משאלת הסקה ומשיחה. תרשים 1 נותן 3,504 ו-1,230. התקציר מעגל כלפי מטה בצורה שמטשטשת את ההבדל בין שני המקרים, ולכן העיתון מדפיס את המספרים מהתרשים.

השלישי הוא מסגור. התקציר פותח בכך שהרצות שונות של אותה משימה יכולות להיבדל פי 30. זה הערך הקיצוני. תרשים 2b מראה שיחס המקסימום למינימום, בממוצע על פני 500 המשימות, הוא כפי 2. העיתון מדפיס את השונות כעובדה ואת פי 30 כקצה, לא כנורמה.

הרביעי הוא הפניה שגויה: פרק 3 מפנה לתרשים 2b בדיון על דיוק מול עלות, אך התרשים הרלוונטי הוא 3b. זו טעות עריכה ולא טעות תוכן, אך היא נרשמת כאן משום שקורא שינסה לבדוק את הטענה יגיע לתרשים הלא נכון.

9. מה לא ניתן היה לאמת

התוצאות הניסיוניות עצמן אינן ניתנות לאימות עצמאי מכאן. אי אפשר להריץ מחדש שמונה מודלים על 500 משימות ארבע פעמים כל אחד, ולכן המספרים שבתרשימים נלקחים כפי שהם, בכפוף לכך שזהות המאמר, מחבריו והתקציר שלו אומתו ב-arXiv.

לא ניתן היה לקבוע אם טעות פי 80 נבעה ממחירון ישן. המאמר הוגש לראשונה ב-24 באפריל 2026, והגרסה שנבדקה עלתה ב-2 באוקטובר. המחירון שהמאמר מפנה אליו הוא דף חי, שמראה היום 50. אם המספר היה נכון באפריל, לא נותר לכך תיעוד שאפשר להצביע עליו, ולכן העיתון מדפיס את היחס שניתן לבדוק עכשיו.

לא נבדק אם הממצאים מחזיקים מחוץ לפייתון, מחוץ ל-SWE-bench ומחוץ ל-OpenHands. אלה שלושה צמצומים שהמאמר אינו מודד מעבר להם, והעיתון אינו מרחיב את מסקנותיו מעבר להם.

1. המאמר עצמו, בגרסה שנבדקה. זהות, תאריכים, שמונה מחברים ותקציר אומתו מול דף המאמר. arXiv:2604.22750v3, How Do AI Agents Spend Your Money? Analyzing and Predicting Token Consumption in Agentic Coding Tasks. הוגש 24.4.2026, גרסה 3 מ-2.10.2026
2. מחירון Anthropic, שמולו נבדק היחס בין טוקן פלט לקריאה מהמטמון ב-15 Claude Sonnet 4.5: דולר מול 0.30 דולר למיליון טוקנים. anthropic.com/pricing
3. אוסף המשימות: 500 תקלות מתוך מאגרי קוד פופולריים בפייתון, לאחר אימות אנושי. שימש לבדיקת היקף התוקף של המאמר. SWE-bench Verified, swebench.com
4. מסגרת הסוכן שבה בוצעו כל ההרצות. OpenHands, All Hands AI
5. המספרים שהעיתון חישב ולא ציטט: 3,504 ו-1,230 כיחסי טוקנים, 116 כיחס עלות, 50 כיחס מחיר, ו-63.9 אחוזים כסכום שלבי החקירה והתיקון. כולם נגזרים מהערכים שבתרשימים 1 ו-8 ומהמחירון, ומקובעים בבדיקה אוטומטית במאגר העיתון. tests/test_newspaper.py

מסמך הרקע נכתב על ידי מערכת "היום בקיצור" לגיליון 12, 9 באוקטובר 2026. הוא נבנה מתוך מאמר שהתקבל ולא מתפרסם, ומתוך בדיקה חוזרת של כל מספר שמגיע לדף המודפס. מקום שבו המאמר והמקור הראשוני אינם מסכימים מסומן בפרק 8. מקום שבו לא הגענו לאימות מסומן בפרק 9.